

激光与光电子学进展

基于改进深度残差收缩网络的分布式光纤声传感信号识别

梁惠康, 谢浩森, 黄红斌, 刘伟平*

暨南大学信息科学技术学院电子工程系, 广东 广州 510623

摘要 提出了基于新阈值函数的深度残差收缩网络(DRSN-NTF), 用于解决分布式光纤声传感(DAS)信号噪声强、识别难的问题。DRSN-NTF 基于深度残差收缩网络(DRSN), 使用新阈值函数代替软阈值函数, 使其更能发挥信号噪声处理器理和分类识别能力。使用 DAS 系统采集周界入侵事件的实验数据, 并通过添加高斯白噪声的形式, 设计了 6 组不同信噪比(0 dB~5 dB)的实验。对比了 4 个模型的实验结果, 由此考察 DRSN-NTF 的识别效果。结果发现: 在强噪声的情况下, DRSN-NTF 取得的平均测试准确率比 DRSN 高 1.05%; 随着信噪比的降低, DRSN-NTF 的测试准确率高于 DRSN 的差值增大, 表明 DRSN-NTF 在信号噪声处理和分类识别能力方面更强, 能获得相对更高的识别准确率。因此, DRSN-NTF 更加适用于 DAS 信号识别。

关键词 光纤光学; 光纤传感器; 模式识别; 深度残差收缩网络; 新阈值函数; 周界安防

中图分类号 TN247 文献标志码 A

DOI: 10.3788/LOP230884

Distributed Optical Fiber Acoustic Sensing Signal Recognition Based on Improved Depth Residual Shrinkage Network

Liang Huikang, Xie Haoshen, Huang Hongbin, Liu Weiping*

Department of Electronic Engineering, College of Information Science and Technology, Jinan University, Guangzhou 510623, Guangdong, China

Abstract Distributed optical fiber acoustic sensing (DAS) signal has problems with strong noise and difficult recognition. To solve these problems, a deep residual shrinkage network based on new threshold function (DRSN-NTF) is proposed. DRSN-NTF uses new threshold function instead of soft threshold function on the basis of deep residual shrinkage network (DRSN), which makes it more capable in signal noise processing and classification recognition. DAS system is used to collect the experimental data of perimeter intrusion events, and six groups of experiment with different signal-to-noise ratios (0 dB~5 dB) are designed by adding Gaussian white noise. The experimental results of the four models are compared to investigate the recognition effect of DRSN-NTF. The results show that the average test accuracy of DRSN-NTF is 1.05% higher than that of DRSN in the case of strong noise. With the reduction of the signal-to-noise ratio, the difference between the test accuracy of DRSN-NTF and that of DRSN increases, indicating that DRSN-NTF is more capable in signal noise processing and classification recognition, which can lead to relatively higher recognition accuracy. Therefore, DRSN-NTF is more suitable for recognition of DAS signal.

Key words fiber optics; fiber optics sensors; pattern recognition; deep residual shrinkage network; new threshold function; perimeter security

1 引言

目前社会对周界安防的要求越来越高, 传统的周界安防技术难以满足现代化管理的需求。分布式光纤声传感(DAS)作为一种新型周界安防技术, 具有动态

测量范围广、灵敏度高、成本低等优势^[1-2], 在周界安防领域的应用越来越广泛^[3]。受到 DAS 系统内部及周界安防监测环境的制约^[4], DAS 信号存在噪声较强、信噪比较低的问题, 从而影响周界入侵事件的识别。本文通过研究 DAS 信号的识别方法, 完成系统对信号的

准确分析及判别。

随着深度学习算法的快速发展,它在DAS信号识别中的应用已经越来越广泛。信号处理算法与深度学习结合,已成为目前的一个主流研究方向,它在增强信号特征的同时能够提高识别的准确率。2020年,Lü等^[5]针对分布式光纤周界安全系统,提出格拉曼角场和卷积神经网络(CNN)相结合的入侵模式识别方法。一维时间序列的入侵信号先经过小波阈值降噪,再经过格拉曼角场算法转换为二维图像输入CNN模型,该方法的信号平均识别准确率可达97.67%。2021年,吴虎等^[6]提出使用经验模态分解和一维CNN结合的方法,用于识别DAS系统的入侵振动事件。该方法首先使用经验模态分解和皮尔逊相关系数得到有效的内涵模态分量(IMF),利用小波阈值去噪算法将其降噪后,将IMF进行求和获得重构后的信号,最后采用一维CNN实现重构后的信号识别。实验证明该识别方法训练时间快,信号的识别准确率达到98.3%。2022年,杨震等^[7]针对相位敏感型光时域反射(Φ -OTDR)的入侵事件识别问题,先对原始时空数据进行归一化、滤波去噪及数据增强,再使用改进的YOLOv3网络进行识别,对三类事件的平均召回率为82.9%,平均准确率为70.4%。上述的研究常在使用深度学习方法之前使用信号滤波算法,这涉及许多参数的选择及设计,如使用小波阈值滤波降噪涉及小波基和分解层数选择等问题,在经验缺乏的情况下会导致有用信号特征在最开始时就被过滤,从而导致信号(特别是具有强噪声特性的DAS信号)识别效果不佳。因此,合适的滤波降噪将会大大提升DAS信号的识别效果,但在缺乏经验时,信号滤波算法如何更好地与光纤传感信号识别任务相结合,这一问题值得思考。

本文将深度残差收缩网络(DRSN)^[8]引入DAS信号的识别研究之中。DRSN在深度残差网络(ResNet)嵌入一个特殊结构,自动获取降噪的阈值,并使用软阈值函数进行降噪处理,在训练中一体化地实现自适应滤波降噪、特征提取能力增强、信号识别任务完成。为了更好地应对周界安防的实际复杂环境,在强噪声的环境下不断提高识别效果,对DRSN进行了改进,提出了基于新阈值函数的深度残差收缩网络(DRSN-NTF)。DRSN-NTF模型使用新阈值函数代替软阈值函数,克服了软阈值函数在信号处理时存在的恒定偏差问题,不会削弱信息特征的一些峰值,保留了信息的显著特征,能够实现更佳的识别效果。

2 DRSN-NTF 理论介绍

2.1 新阈值函数

张维强等^[9-10]提出了一种基于新阈值函数的小波域信号去噪方法。通过实验发现,新阈值方法与传统的软硬阈值方法相比,能够取得更为理想的去噪效果。新阈值函数的数学表达式为

$$\hat{x} = \begin{cases} \operatorname{sgn}(x) \left\{ |x| - \tau / \exp[(|x| - \tau) / N] \right\}, & |x| \geq \tau \\ 0, & |x| < \tau \end{cases}, \quad (1)$$

式中: \hat{x} 为输出的特征; x 为输入的特征; $\operatorname{sgn}(x)$ 为符号函数,表示返回一个数的正负; τ 为阈值; N 为任意常数。

新阈值函数克服了软硬阈值函数的缺点。第一,新阈值函数与软阈值函数一样具有连续性,不存在硬阈值函数出现的不连续问题;第二,新阈值函数以 $\hat{x} = x$ 为渐近线,当 $x \geq \tau$ 时随着 x 的增大 \hat{x} 逐渐接近 x ,当 $x \leq -\tau$ 时随着 x 的减小 \hat{x} 逐渐接近 x ,不存在软阈值函数 \hat{x} 与 x 之间的恒定偏差。同时,新阈值函数是介于软阈值和硬阈值函数之间的一个灵活选择,可以通过 N 的取值,得到有效的阈值函数。当 $N \rightarrow \infty$,式(1)为软阈值函数;当 $N \rightarrow 0$,式(1)为硬阈值函数。新阈值函数的图像如图1所示,其中 $N = 4, \tau = 3$ 。

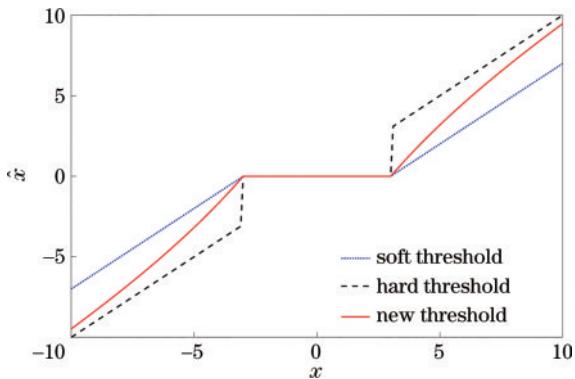


图1 3种阈值函数的对比
Fig. 1 Comparison of three threshold functions

2.2 DRSN-NTF 原理及结构

DRSN非常适合于具有强噪声特性的信号,目前已在信号识别的多个领域取得了很好的应用效果。它在ResNet^[11]嵌入一个特殊模块,以注意力机制^[12]的方式自动获取用于信息降噪的阈值,并使用软阈值函数进行阈值降噪处理。

所提DRSN-NTF是在DRSN的基础上进行改进。与DRSN不同的是,DRSN-NTF使用的是基于新阈值函数的残差收缩单元(RSBU-NTF),如图2所示,它使用了新阈值函数代替了DRSN的软阈值函数。RSBU-NTF含有一个特殊模块,用于估计实现新阈值函数所需要的阈值。RSBU-NTF的阈值计算过程如下:1)以尺寸为 $C \times W \times 1$ 的特征图作为单元的输入,其中, C 、 W 分别为特征图的通道数、宽度,以一维振动信号作为输入数据,因此特征图的高度始终都为1;2)输入的特征图先进行两个卷积层(Conv)的训练,其中,BN表示批量标准化,ReLU表示激活函数的一种, K 表示卷积核的数量;3)在特殊模块中,先进行绝对值(absolute)处理,接着使用全局均值池化(GAP)获得长度等于通道数的一维向量 α ;4)这个一维向量 α 通过

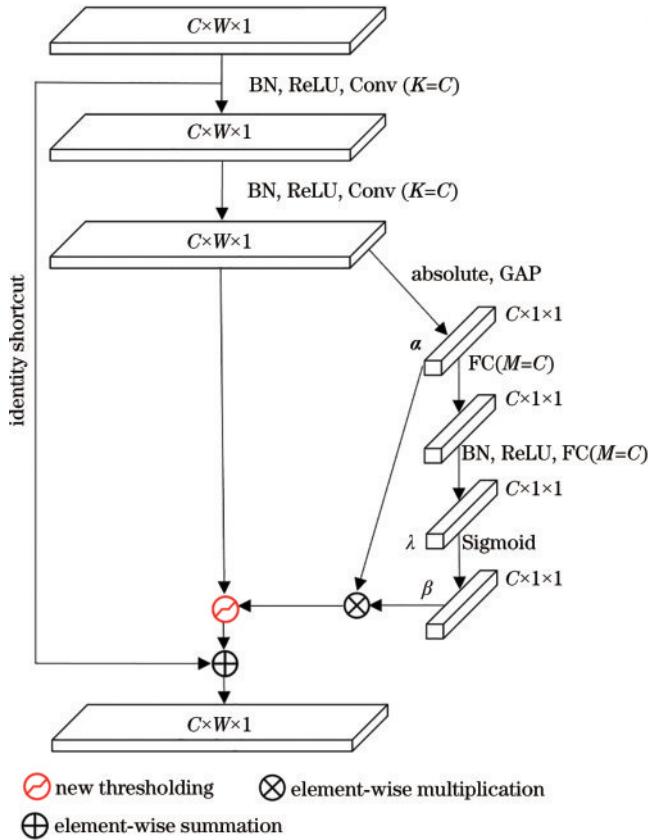


图 2 基于新阈值函数的 RSBU-NTF 结构

Fig. 2 Structure of RSBU-NTF based on new threshold function

两层全连接层(FC)后,获得一维向量的尺度化参数 λ ,其中, M 表示神经元的数量;5)利用 Sigmoid 函数实现尺度化参数 λ 在 0~1 范围内的映射,得到尺度化参数 β ;6)RSBU-NTF 的阈值 τ 等于尺度化参数 β 和一维向量 α 的乘积。在阈值计算结束后,使用新阈值函数对多通道特征图进行信息过滤。

3 DAS 周界安防系统实验及数据处理

3.1 系统框图

利用基于 Φ -OTDR 直接检测的 DAS 系统来构建周界安防的应用场景,其系统框图如图 3 所示。

DAS 周界安防系统的实施步骤如下:1)由窄线宽激光器(laser)输出持续的光信号。2)该光信号被声光调制器(AOM)调制成脉冲光信号。其中,由现场可编程门阵列(FPGA)为 AOM 提供脉冲频率 1~10 kHz、脉宽 10~100 ns 可调的驱动。3)脉冲光通过掺铒光纤放大器(EDFA)实现光信号能量的放大。4)放大后的脉冲光信号进入环形器(circulator)1 端口,从 circulator 2 端口进入到传感光纤。其中,传感光纤使用的是 11 km 普通单模光纤(SMF)。在实际的周界环境中,SMF 一般部署在周界防盗网上或者埋设在土地里,光纤沿线设置传感点个数 $L_1 \sim L_s$ 。5)在 SMF 的传输过程中使用拉曼放大器(RFA)对光信号继续放大,保证光信号的能量强度。6)光信号在光纤传输过程中会产生瑞利散射。对于外界的入侵事件,周界光纤不同测量点的扰动变化会引起对应的瑞利散射变化。7)后向瑞利散射会沿着传感光纤返回环形器,从 circulator 3 端口输出光信号。8)光电探测器(PD)接收到光信号后,完成将光信号转为电信号的任务。9)由数据采集卡(DAQ)对电信号进行模数转换。根据系统设定的采样率,采集到一条条瑞利散射曲线数据,形成时间-空间数据矩阵。10)由数字信号处理(DSP)算法解调出扰动信号。使用振幅差分法得到扰动点位置,进而解调出扰动信号。

埋设在土地里,光纤沿线设置传感点个数 $L_1 \sim L_s$ 。5)在 SMF 的传输过程中使用拉曼放大器(RFA)对光信号继续放大,保证光信号的能量强度。6)光信号在光纤传输过程中会产生瑞利散射。对于外界的入侵事件,周界光纤不同测量点的扰动变化会引起对应的瑞利散射变化。7)后向瑞利散射会沿着传感光纤返回环形器,从 circulator 3 端口输出光信号。8)光电探测器(PD)接收到光信号后,完成将光信号转为电信号的任务。9)由数据采集卡(DAQ)对电信号进行模数转换。根据系统设定的采样率,采集到一条条瑞利散射曲线数据,形成时间-空间数据矩阵。10)由数字信号处理(DSP)算法解调出扰动信号。使用振幅差分法得到扰动点位置,进而解调出扰动信号。

3.2 实验数据集

在实验室的环境下,使用 DAS 周界安防系统来采集相关的信号数据。设计了 6 种振动事件,分别为拍打、走路、碾压、噪声、攀爬和浇水。每个事件在实际环境中有各自的代表意义:1)拍打,模拟入侵者对周界系统进行破坏时的振动情况;2)走路,模拟有行人走过时的振动情况;3)碾压,模拟有车辆经过时的振动情况;4)噪声,模拟实际环境中无扰动的情况;5)攀爬,模拟有人攀爬时的振动情况;6)浇水,模拟实际环境中下雨时的振动情况。图 4 为上述 6 种振动事件的时域信号波形,为了更好地观察信号的情况,截取其中 0.2 s 时域波形进行展示。从图 4 可以看出,各振动事件的时域信号特征有着明显的差异。

每个振动事件分别采集 1000 个样本,构成总样本数量为 6000 的实验数据集。每个样本的振动信号采集时间长度为 1 s。由于实验设置的信号采样频率为 8000 Hz,因此每个样本的振动信号数据点为 8000 s⁻¹。因此,参与实验的每个信号样本以通道为 1、宽度为 8000、高度为 1 的信号形式($1 \times 8000 \times 1$)作为模型训练及预测的输入。

DAS 系统的实际工作环境更加复杂多样,往往会产生大量且不同的干扰噪声,这将会给 DAS 信号的识别带来极大的困难。在周界安防系统中,如果噪声干扰导致信号识别不准确或者被误判,系统将起不到报警防范的作用,会带来重大的经济损失,甚至是严重的安全事故。设置更强噪声的实验数据集并将其用于考察深度学习方法的识别效果,成为开展识别研究的重要准备工作。在实验数据集的基础上,以添加高斯白噪声的方式,获取更强噪声的实验数据集。设计 6 组不同信噪比(0 dB~5 dB)的数据集,并且分别开展识别实验。信噪比的数学表达式为

$$R_{\text{SNR}} = 10 \log(P_s/P_n), \quad (2)$$

式中: R_{SNR} 为信号的信噪比; P_s 为信号的功率; P_n 为噪声的功率。

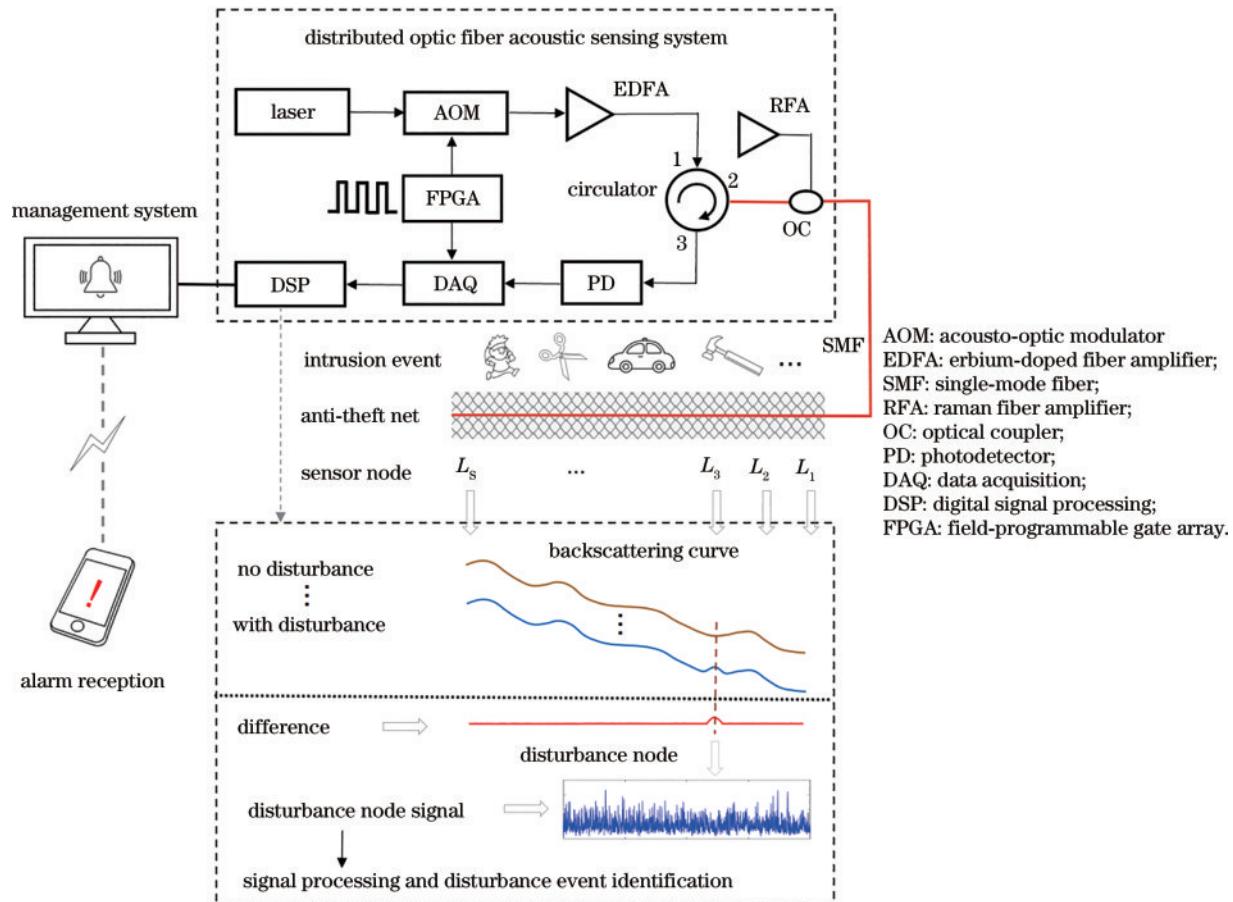


图 3 DAS 周界安防系统框架
Fig. 3 Block diagram of DAS perimeter security system

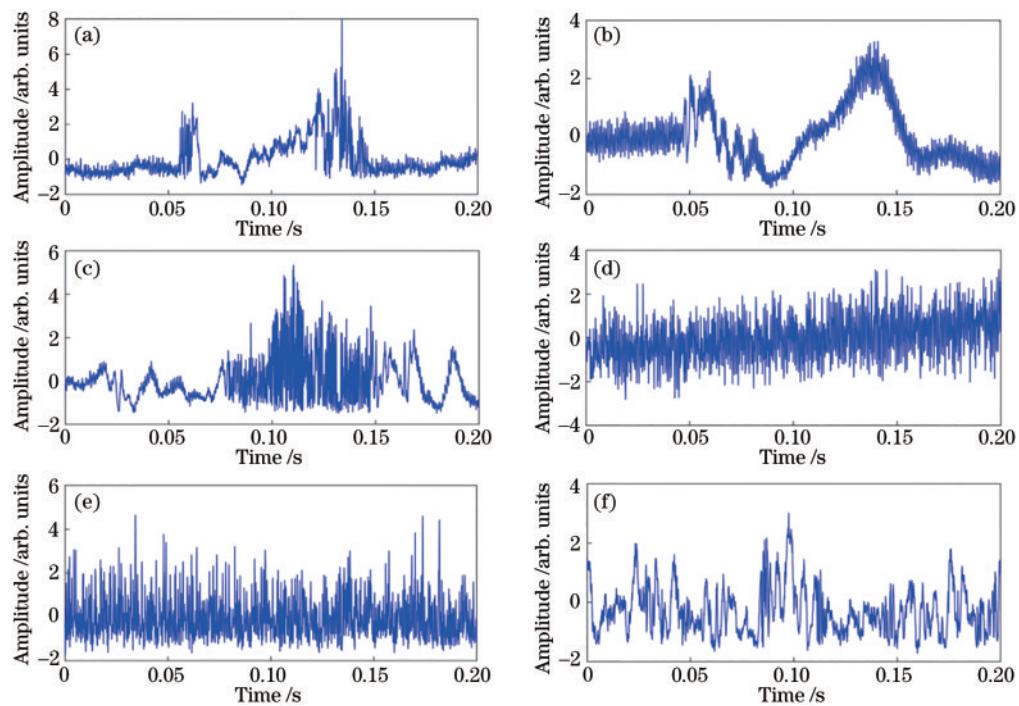


图 4 各振动事件的信号时域波形图。(a)拍打;(b)走路;(c)碾压;(d)噪声;(e)攀爬;(f)浇水
Fig. 4 Time domain signal waveforms of different vibration events. (a) Clap; (b) walk; (c) rolling; (d) noise; (e) climbing; (f) watering

4 实验结果分析

4.1 实验准备

对比 CNN、ResNet、DRSN、DRSN-NTF 4 个模型的实验结果,由此考察 DRSN-NTF 在强噪声环境下的识别效果。实验训练集和测试集的划分采用的是十折交叉验证法,即将实验数据集平均划分为 10 个子集,每次实验将 1 个子集作为测试集,另外 9 个子集作为训练集。实验重复 10 次,使每个子集都有一次作为测试集的机会,结果取 10 次实验的平均值。实验需设置的超参数^[13]包括结构相关的超参数和优化相关的超参数。

表 1 CNN、ResNet、DRSN、DRSN-NTF 结构相关的超参数

Table 1 Structure-related superparameters of CNN, ResNet, DRSN and DRSN-NTF

CNN	ResNet	DRSN	DRSN-NTF	Output size
Input	Input	Input	Input	$1 \times 8000 \times 1$
Conv(4, 3, /2)	Conv(4, 3, /2)	Conv(4, 3, /2)	Conv(4, 3, /2)	$4 \times 4000 \times 1$
CBU(4, 3, /2)	RBU(4, 3, /2)	RSBU(4, 3, /2)	RSBU-NTF(4, 3, /2)	$4 \times 2000 \times 1$
CBU(4, 3)	RBU(4, 3)	RSBU(4, 3)	RSBU-NTF(4, 3)	$4 \times 2000 \times 1$
CBU(8, 3, /2)	RBU(8, 3, /2)	RSBU(8, 3, /2)	RSBU-NTF(8, 3, /2)	$8 \times 1000 \times 1$
CBU(8, 3)	RBU(8, 3)	RSBU(8, 3)	RSBU-NTF(8, 3)	$8 \times 1000 \times 1$
CBU(16, 3, /2)	RBU(16, 3, /2)	RSBU(16, 3, /2)	RSBU-NTF(16, 3, /2)	$16 \times 500 \times 1$
CBU(16, 3)	RBU(16, 3)	RSBU(16, 3)	RSBU-NTF(16, 3)	$16 \times 500 \times 1$
BN, ReLU, GAP	BN, ReLU, GAP	BN, ReLU, GAP	BN, ReLU, GAP	$16 \times 1 \times 1$
FC	FC	FC	FC	$6 \times 1 \times 1$

2) 优化相关的超参数。训练迭代周期为 100 次;学习率逐层递减,前面 40 个周期学习率为 0.1,之后 40 个周期学习率为 0.01,最后 20 个周期学习率为 0.001;训练的批量大小为 128;动量系数设置为 0.9;添加 L2 正则化方法,惩罚项的系数为 0.0001。

4.2 CNN、ResNet、DRSN、DRSN-NTF 的识别准确率

对比实验在 AMD Ryzen7 2700X 处理器和英伟达 GeForce GTX2080-O8G GPU 的计算机上进行,并使用机器学习的 TensorFlow 框架。

表 2 为在 0 dB~5 dB 信噪比情况下,对 6 组实验结果取平均值后的 4 个模型的识别准确率。在强噪声的

1) 结构相关的超参数。4 个模型须设置一致,以保证 4 者的可对比性,如表 1 所示,4 个模型的核心区别在于它们使用不同的单元模块,分别为卷积单元(CBU)、残差单元(RBU)、残差收缩单元(RSBU)、RSBU-NTF。该超参数的详细说明如下:①均以尺寸为 $1 \times 8000 \times 1$ 的振动信号作为模型的输入;②特征图通道数按照 4、8、16 递增;③卷积核大小取 $1 \times 3, /2$ 表示卷积核的移动步长为 2,每次 $/2$ 操作后特征图的宽度将缩小一半;④经过 GAP 后,特征图将缩减成数量为 16 的一维向量;⑤经过 FC 后变成数量为 6 的一维向量,与 6 个振动事件标签的数量相等。

表 2 CNN、ResNet、DRSN、DRSN-NTF 的平均识别准确率

Table 2 Average recognition accuracy of CNN, ResNet, DRSN and DRSN-NTF

情况下,DRSN、DRSN-NTF 的识别准确率均高于 ResNet、CNN。DRSN、DRSN-NTF 的平均测试准确率均高于 91.50%,ResNet、CNN 均低于 89.50%。特别地,DRSN-NTF 的识别准确率均高于其他 3 个网络。第一,训练准确率方面,取得平均训练准确率最高的是 DRSN-NTF,高达 97.99%,比 DRSN 高 0.61 个百分点,比 ResNet 高 2.08 个百分点,比 CNN 高 6.50 个百分点。第二,测试准确率方面,取得平均测试准确率最高的是 DRSN-NTF,高达 92.82%,比 DRSN 高 1.05 个百分点,比 ResNet 高 3.52 个百分点,比 CNN 高 6.66 个百分点。

表 2 CNN、ResNet、DRSN、DRSN-NTF 的平均识别准确率

Table 2 Average recognition accuracy of CNN, ResNet, DRSN and DRSN-NTF

Network	Average training accuracy /%	Average test accuracy /%	Average training time /s
DRSN-NTF	97.99	92.82	238
DRSN	97.38	91.77	220
ResNet	95.91	89.30	154
CNN	91.49	86.16	150

DRSN 和 DRSN-NTF 的平均训练时间均比 ResNet、CNN 要高一些。因为 DRSN 和 DRSN-NTF 设计了一个特殊模块来估计阈值并进行阈值化处理,用于消除特征图的噪声信息。因此,它们在提高信号识别准确率的同时,训练速度会相对变慢。DRSN-

NTF 的平均训练时间为 238 s,比 DRSN 的平均训练时间多 18 s,因为 DRSN-NTF 以新阈值函数取代软阈值函数,与软阈值函数相比,新阈值函数的运算稍微复杂一点。

4.3 DRSN-NTF 与 DRSN 的比较

从测试准确率、准确率和损失的迭代曲线、F1-score 性能评估指标 3 个方面,详细比较 DRSN-NTF 与 DRSN 的识别效果。

4.3.1 测试准确率

在 0 dB~5 dB 信噪比的情况下,DRSN-NTF 与 DRSN 取得的测试准确率如表 3 所示。在信噪比为 3 dB、4 dB、5 dB 的情况下,DRSN-NTF 与 DRSN 的测试准确率差值较小(均 ≤ 0.90 个百分点);在信噪比为

0 dB、1 dB、2 dB 的情况下,DRSN-NTF 与 DRSN 的测试准确率差值较大(均 ≥ 1.27 个百分点)。从表 3 可以看出,在信噪比较低的情况下,DRSN-NTF 与 DRSN 的测试准确率差值增大。因此,可以得出结论:DAS 信号的噪声越强,与 DRSN 中的软阈值函数相比,DRSN-NTF 的新阈值函数在处理信号噪声方面更有优势,更能发挥其分类识别能力,取得相对更高的识别准确率。实验表明,DRSN-NTF 更适用于具有强噪声特性的 DAS 信号识别。

表 3 DRSN、DRSN-NTF 的测试准确率对比结果

Table 3 Comparison results of test accuracy of DRSN and DRSN-NTF

Signal-to-noise ratio /dB	Test accuracy of two networks /%		Difference between DRSN and DRSN-NTF /percentage point
	DRSN	DRSN-NTF	
5	94.73	95.35	0.62
4	93.55	94.45	0.90
3	93.33	94.08	0.75
2	91.47	92.80	1.33
1	90.18	91.63	1.45
0	87.35	88.62	1.27
Average value	91.77	92.82	1.05

4.3.2 准确率和损失的迭代曲线

图 5(a)、(b) 分别展示了随着训练过程中迭代周期的增加,DRSN-NTF、DRSN 的训练准确率和训练损失的变化情况。从图 5 可以看出,在训练过程中 DRSN-NTF 的训练准确率明显高于 DRSN,损失明显低于 DRSN,表明 DRSN-NTF 比 DRSN 有更佳的模型训练效果。在收敛速度方面,两个模型在最开始的时候都是以非常快的速度进行收敛,但是大概在迭代

周期 5~60 这个区间,DRSN 的收敛速度放缓,而 DRSN-NTF 仍保持较高的收敛速度。这是因为 DRSN-NTF 使用的新阈值方法克服了软阈值方法在处理数据时存在的恒定偏差问题,未削弱信息特征的一些峰值,而更容易获得准确的训练结果。所以 DRSN-NTF 在加快收敛速度的同时,也能够获得更好的训练结果。

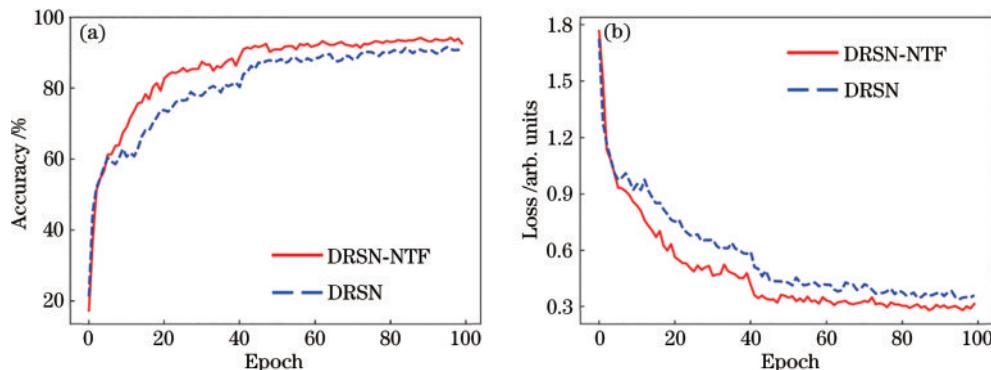


图 5 当 $R_{\text{SNR}}=1 \text{ dB}$ 时,两个模型在训练过程中的准确率和损失迭代曲线。(a)准确率;(b)损失迭代曲线

Fig. 5 When $R_{\text{SNR}}=1 \text{ dB}$, accuracy and loss iteration curves of the two models in the training process. (a) Accuracy; (b) loss iteration curves

4.3.3 性能指标

表 4 是 DRSN-NTF、DRSN 两个模型的平均 F1-score 性能评估指标结果。从表 4 中可以看出,DRSN-NTF 的 F1-score 值明显优于 DRSN,表明 DRSN-NTF 很好地完成了 6 类标签的分类任务,具有更强的分类识别能力。两个模型在标签 1、2、4 都取得了很好的分

类效果,标签 1、4 的性能指标数值等于或大于 0.98,标签 2 的性能指标数值等于或大于 0.94。所以,真正能够区分两个模型分类识别能力的是标签 3、5、6 的分类结果。DRSN-NTF 关于标签 3 的平均 F1-score 值比 DRSN 高 0.02;DRSN-NTF 关于标签 5 的平均 F1-score 值比 DRSN 高 0.04;DRSN-NTF 关于标签 6 的

表4 当 $R_{SNR}=1$ dB 时,DRSN、DRSN-NTF 的平均 F1-score 值
对比结果

Table 4 When $R_{SNR}=1$ dB, the comparison results of the average F1-score values of DRSN and DRSN-NTF

Label	Vibration event	Average F1-score value	
		DRSN	DRSN-NTF
1	Clap	0.98	0.98
2	Walk	0.94	0.95
3	Rolling	0.87	0.89
4	Noise	0.99	0.99
5	Climbing	0.79	0.83
6	Watering	0.84	0.86

平均 F1-score 值比 DRSN 高 0.02。因此,在标签 3、5、6 上,DRSN-NTF 比 DRSN 的分类结果更好。

5 结 论

创新地提出 DRSN-NTF, 将表现更佳的信号处理算法融入到深度学习方法之中, 使信号增强和分类识别的功能结为一体, 不断地提升强噪声信号的识别能力, 为 DAS 信号识别研究提供了一个新角度。DRSN-NTF 针对 DAS 信号噪声强、难识别的问题, 从阈值处理算法入手提出新的深度学习解决方案, 充分利用新阈值函数在噪声处理上的优势, 与 DRSN 融合后发挥出较强的噪声处理能力和分类识别能力。通过实验发现, 在强噪声的情况下, DRSN-NTF 取得的平均测试准确率比 DRSN 高 1.05 个百分点。随着信噪比的降低, DRSN-NTF 与 DRSN 的测试准确率差值增大, 表明噪声越强, DRSN-NTF 越能发挥其在信号处理方面的优势, 获得更为理想的识别结果。下一步, 将继续从信号处理算法与深度学习方法融合的角度提出优化的思路, 不断提升 DAS 信号的识别效果。

参 考 文 献

- [1] Culshaw B, Kersey A. Fiber-optic sensing: a historical perspective[J]. Journal of Lightwave Technology, 2008, 26(9): 1064-1078.
- [2] Barrius A, Casas J R, Villalba S. A review of distributed optical fiber sensors for civil engineering applications[J]. Sensors, 2016, 16(5): 748.
- [3] 李玉, 刘铁根, 王绍俊, 等. 全光纤分布式视频联动长距离周界安防监控系统[J]. 光电子·激光, 2013, 24(9): 1752-1757.
Li Y, Liu T G, Wang S J, et al. All fiber distributed long-distance perimeter security monitoring system with video linkage function[J]. Journal of Optoelectronics·Laser, 2013, 24(9): 1752-1757.
- [4] 王角. 分布式光纤传感振动信号二维去噪方法研究[D]. 北京: 北京邮电大学, 2021.
- [5] Wang J. Research on two-dimensional denoising method of distributed optical fiber sensing vibration signal[D]. Beijing: Beijing University of Posts and Telecommunications, 2021.
- [6] Lü C G, Huo Z Q, Cheng X, et al. Distributed optical fiber sensing intrusion pattern recognition based on GAF and CNN[J]. Journal of Lightwave Technology, 2020, 38(15): 4174-4182.
- [7] 吴虎, 孔勇, 王振伟, 等. 基于 EMD 分解与 1-D CNN 算法的光纤振动信号的识别[J]. 激光与红外, 2021, 51(8): 1043-1049.
Wu H, Kong Y, Wang Z W, et al. Recognition of optical fiber vibration signals based on VMDCNN algorithm[J]. Laser & Infrared, 2021, 51(8): 1043-1049.
- [8] 杨震, 封皓. 基于深度学习的 Φ -OTDR 输油管道入侵监测研究[J]. 激光与光电子学进展, 2022, 59(8): 0806001.
Yang Z, Feng H. Oil pipeline intrusion monitoring based on deep learning of Φ -OTDR[J]. Laser & Optoelectronics Progress, 2022, 59(8): 0806001.
- [9] Zhao M H, Zhong S S, Fu X Y, et al. Deep residual shrinkage networks for fault diagnosis[J]. IEEE Transactions on Industrial Informatics, 2020, 16(7): 4681-4690.
- [10] 张维强, 宋国乡. 基于一种新的阈值函数的小波域信号去噪[J]. 西安电子科技大学学报, 2004, 31(2): 296-299, 303.
Zhang W Q, Song G X. Signal de-noising in wavelet domain based on a new kind of thresholding function[J]. Journal of Xidian University, 2004, 31(2): 296-299, 303.
- [11] 张维强. 小波和神经网络在模拟电路故障诊断中的应用研究[D]. 西安: 西安电子科技大学, 2006.
- [12] Zhang W Q. Research on application of wavelet and neural network in analog circuit fault diagnosis[D]. Xi'an: Xidian University, 2006.
- [13] He K M, Zhang X Y, Ren S Q, et al. Deep residual learning for image recognition[C]//2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), June 27-30, 2016, Las Vegas, NV, USA. New York: IEEE Press, 2016: 770-778.
- [14] Hu J, Shen L, Sun G. Squeeze-and-excitation networks [C]//2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, June 18-23, 2018, Salt Lake City, UT, USA. New York: IEEE Press, 2018: 7132-7141.
- [15] Liang H K, Xie H S, Huang H B, et al. Distributed optical fiber sensing signal recognition based on deep residual shrinkage network[C]//2022 5th World Conference on Mechanical Engineering and Intelligent Manufacturing (WCMEIM), November 18-20, 2022, Ma'anshan, China. New York: IEEE Press, 2023: 882-886.